



# Quantum Machine Learning Seminar

# Método Kernel, Maquinas de Soporte Vectorial (SVM) y Mapa Cuántico de Características

Quantum Machine Learning Seminar

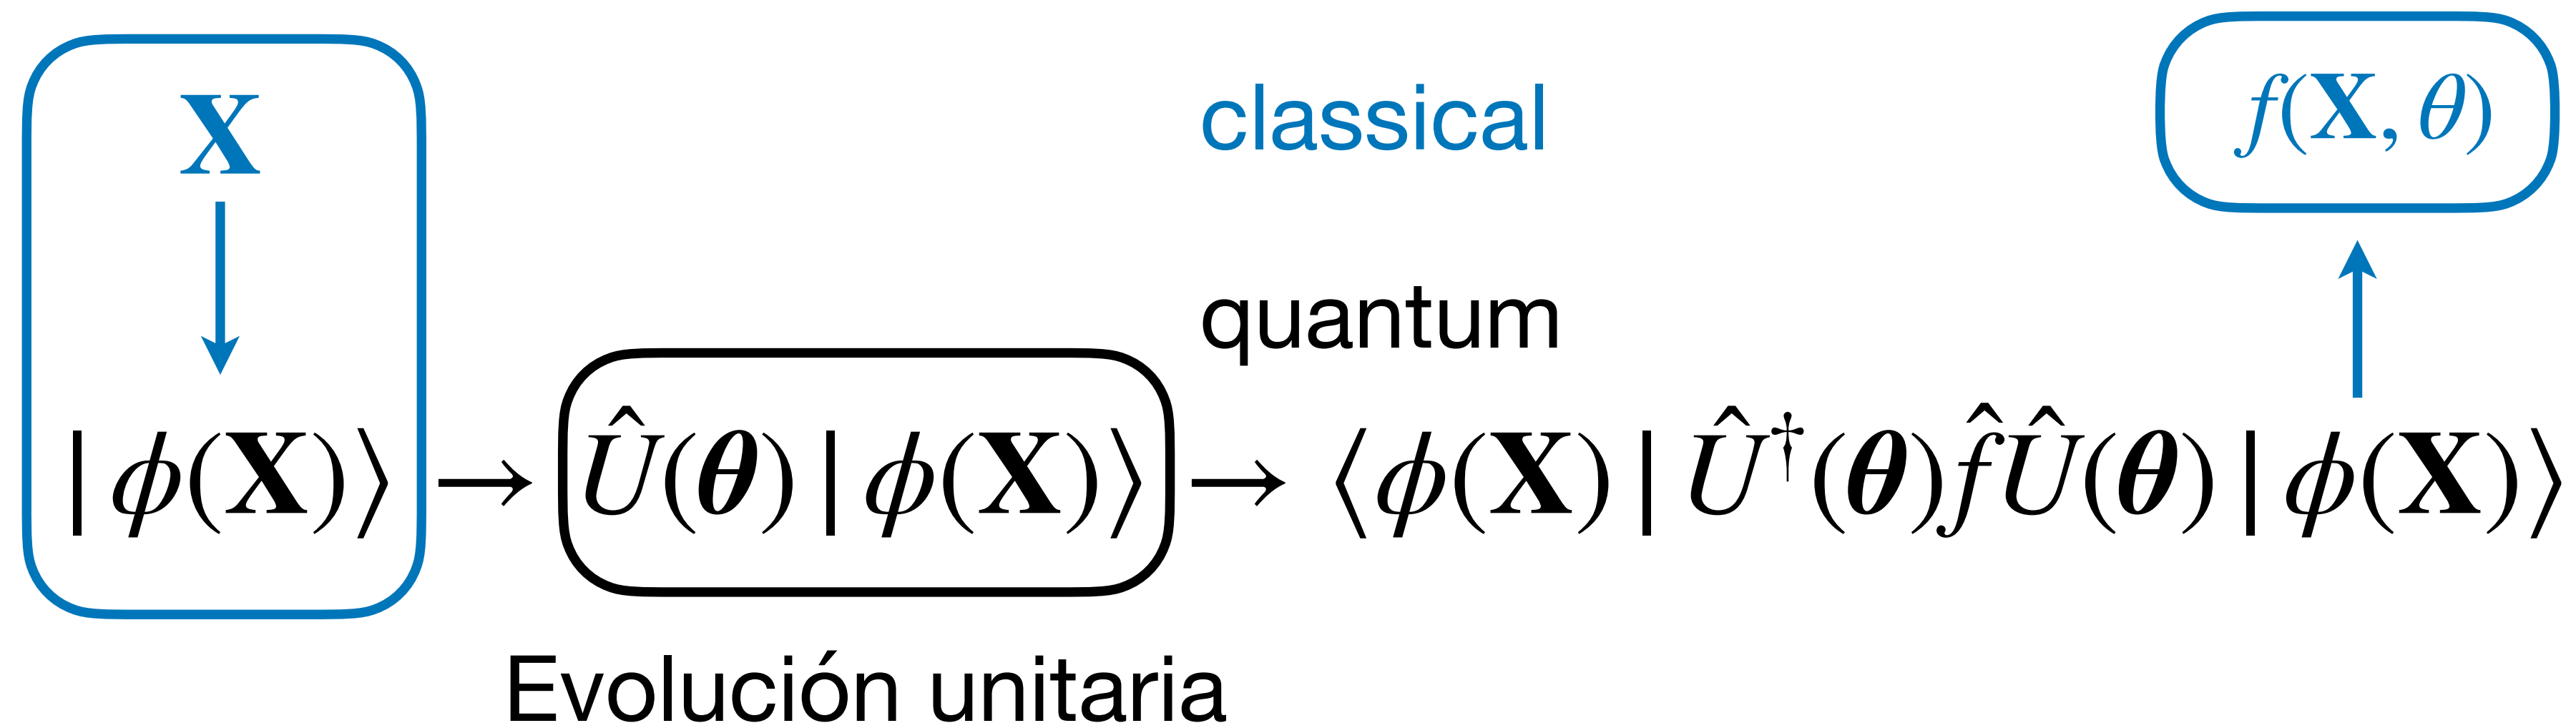
Cristian E. Bello, May 31, 2025



# Mapa Cuántico de Características


Codificación cuántica

Medición del observable



QNN como aproximadores universales si se diseñan correctamente.

# Mapa Cuántico de Características



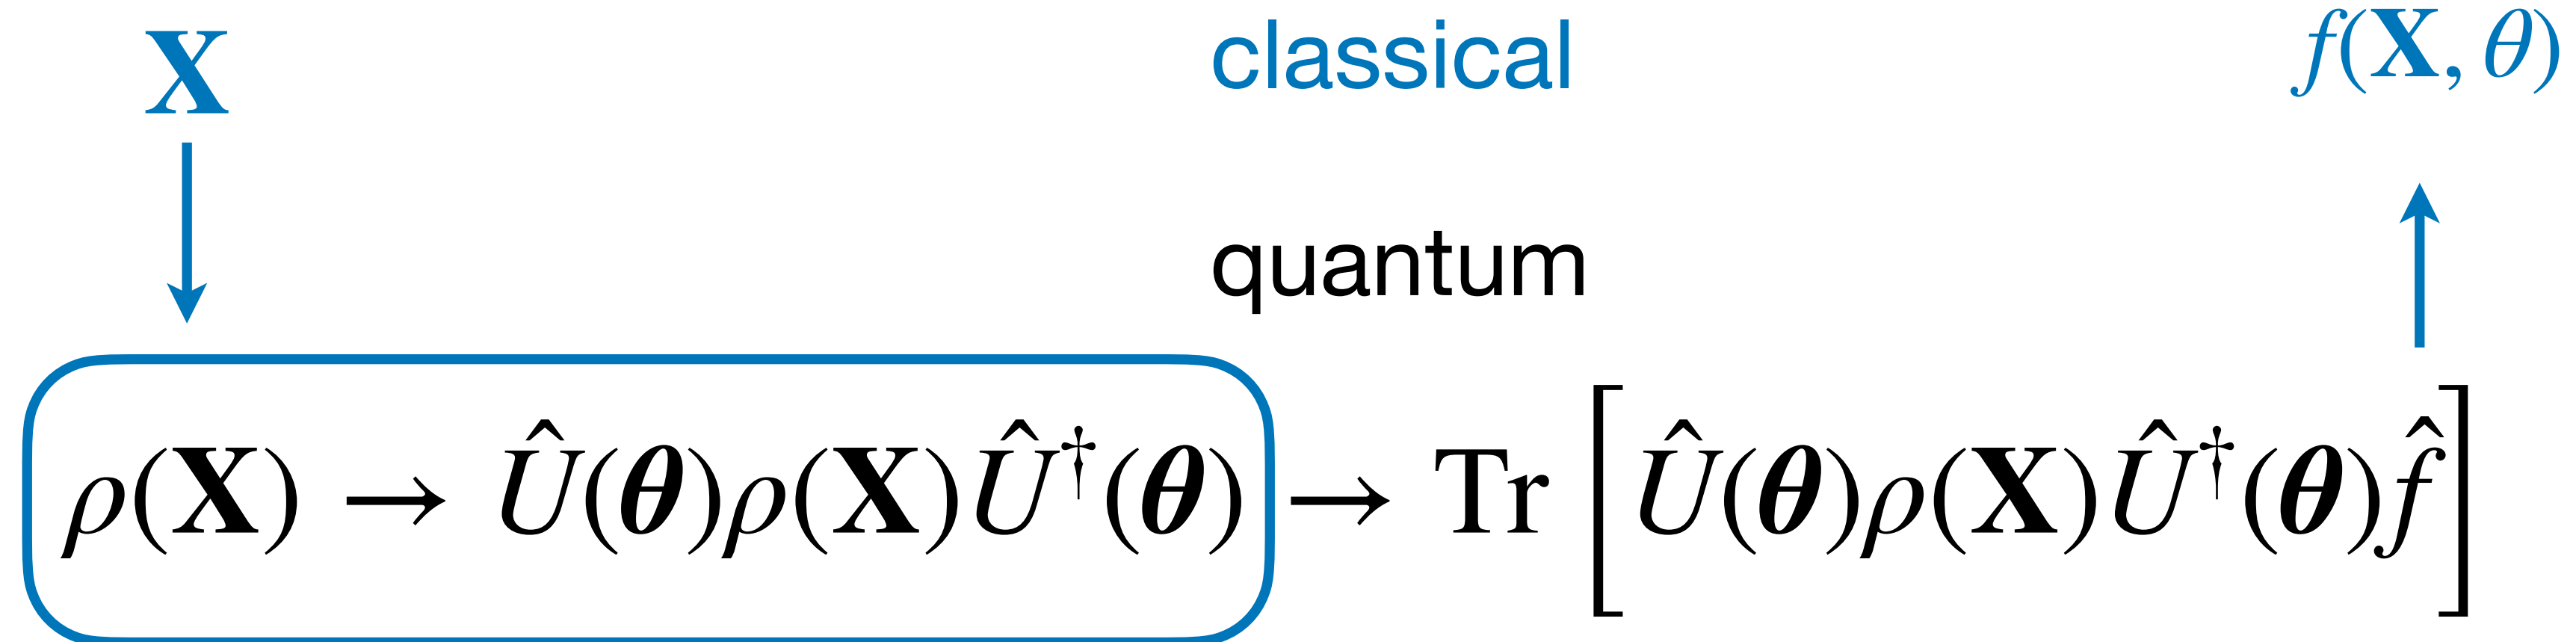
**Table 2.1** Examples of supervised pattern classification tasks in real-life applications

Input	Output
<i>Regression tasks</i>	
Last month’s oil price	Tomorrow’s oil price
Search history of a user	Chance to click on a car ad
Insurance customer details	Chance of claiming
<i>Multi-label classification tasks</i>	
Images	Cat, dog or plane?
Recording of speech	Words contained in speech
Text segment	Prediction of next word to follow
<i>Binary classification tasks</i>	
Text	Links to terrorism?
Video	Contains a cat?
Email	Is spam?
Spectrum of cancer cell	Malicious?

# Representación del Estado Cuántico

Representación

Medición



Kets vs matrices de densidad

# Pros y Contras de las Redes Neuronales Cuánticas

Las redes neuronales cuánticas pueden considerarse una implementación de paradigmas de computación clásica.

## Pros:

1. Ejemplo: para  $d$  #qúbits, el espacio de Hilbert tiene una dimensión  $N = 2^d$ . Para  $d = 100$ , tenemos  $N = 1030$  órdenes de magnitud mayores que el número de estrellas en el universo.



<https://research.ibm.com/blog/127-qubit-quantum-processor-eagle>

## Contras:

1. El entrelazamiento a gran escala es difícil de soportar al interactuar con el mundo clásico. Los estados más amigables abarcan un espacio más pequeño  $2D$ .
2. Las mediciones cuánticas son probabilísticas.
3. Limitaciones intrínsecas (no-clonación, no podemos acceder a un registro cuántico sin colapsar su estado).

# Método Kernel


En los métodos kernel, el objetivo es aproximar una función desconocida  $f(\mathbf{X})$  mediante el uso de un conjunto de datos  $[\mathbf{X}^{(i)}, y_i]$  determinado por las observaciones  $\mathbf{X}^{(i)}$  (es decir, los datos de entrada) y las etiquetas  $y_i$ , con  $i = 0, 1, \dots, N_x - 1$

$$f(\mathbf{X}) = \sum_{i=0}^{N_x-1} \alpha_i y_i K[\mathbf{X}, \mathbf{X}^{(i)}]$$

Propiedades: Simétrica  $K(X, Y) = K(Y, X)$ , definida positivamente.



# Método Kernel



Mapeo a funciones etiquetadas por datos.



# SVM: La Calle Más Ancha



Un algoritmo para clasificar datos linealmente separables.

$$f(\mathbf{X}) = \sum_{i=0}^{N_X-1} \alpha_i y_i K [\mathbf{X}, \mathbf{X}^{(i)}]$$

Consideramos el caso en el que la medida de similitud es simplemente el producto escalar, es decir,

$$K_{ij} = \mathbf{X}^{(i)} \cdot \mathbf{X}^{(j)}$$

# SVM: La Calle Más Ancha



Maximización del margen:  $y_i (X^{(i)} \cdot w + b) \geq 1$        $w = \sum_i \alpha_i y_i X^{(i)}$

# Kernel Machines vs Perceptron

El perceptron es la red neuronal de una capa más simple.

$$f(\mathbf{X}) = g(\mathbf{w} \cdot \mathbf{X}) = g \left( \sum_{q=0}^{D-1} w^q X^q \right)$$

↓  
Vector de pesos

Función de activación

La SVM es un perceptron tal que  $w$  es una combinación lineal de los vectores de entrada  $\mathbf{X}^{(j)}$ .



# Maapeo Cuántico de Características y Kernels Cuánticos

Mapa de características cuánticas

$$X \mapsto |\phi(X)\rangle \circ \rho(X)$$

Kernel

$$K_Q(X, X') = \left| \langle \phi(X) | \phi(X') \rangle \right|^2$$

Para Quantum Machine Learning, necesitamos encontrar un mapa de características que permita representar y entrenar funciones arbitrarias.

# Mapeo Cuántico de Características y Kernels Cuánticos

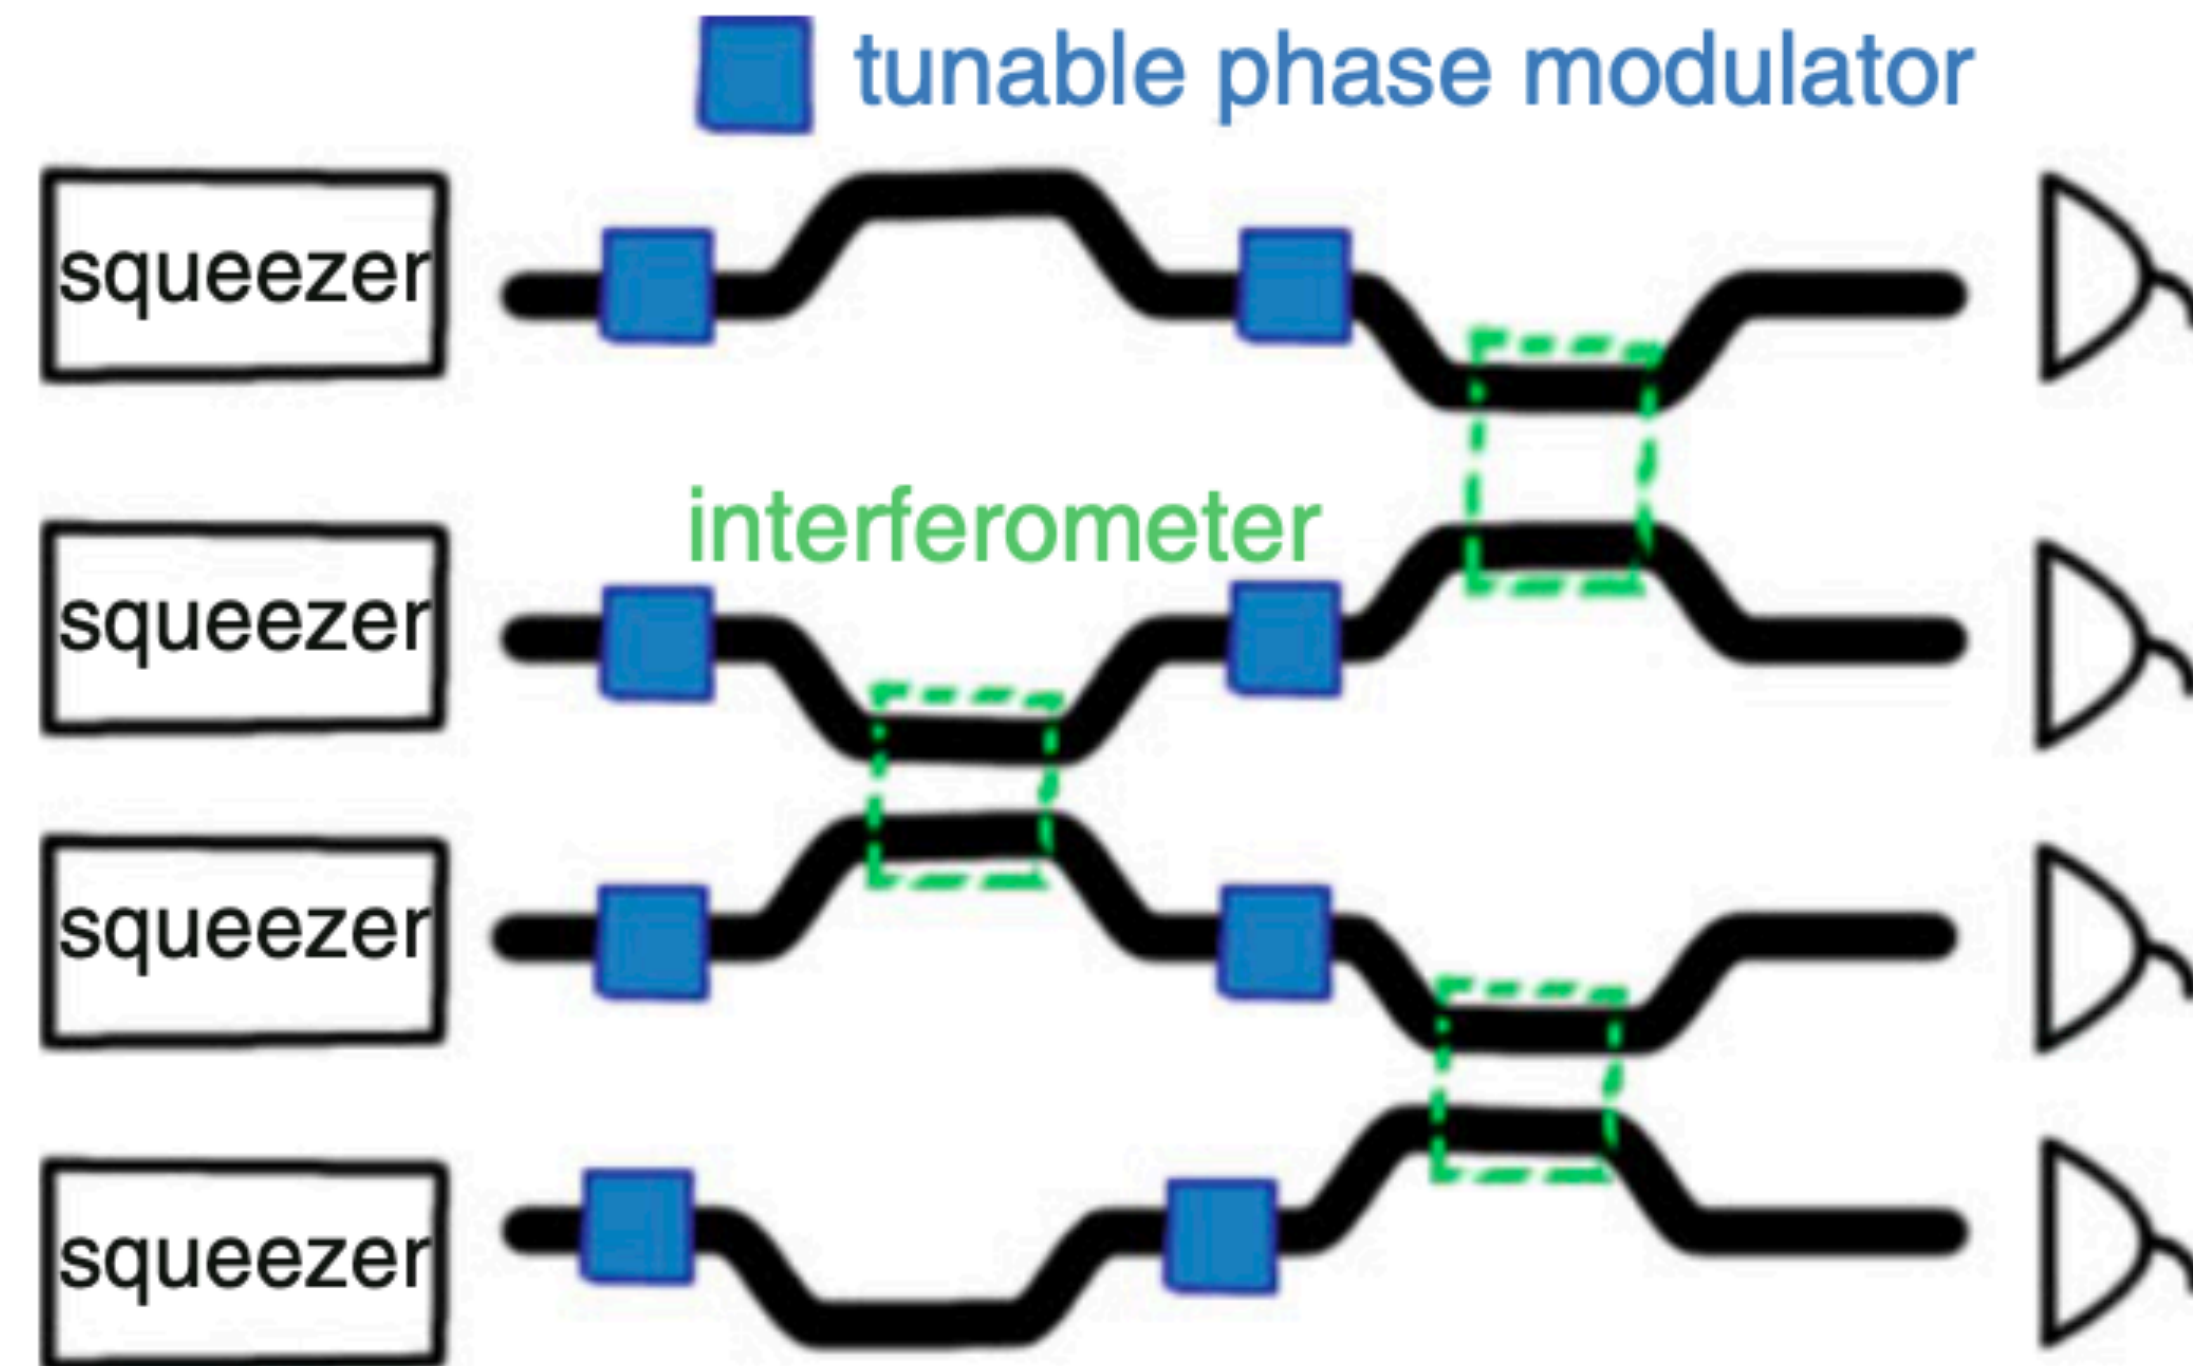
Modelo:

1. Mape todos los puntos en los conjuntos de datos en estados cuánticos.
2. Calcule los productos escalar utilizando el dispositivo cuántico.
3. Invierta la matriz de gram para determinar los pesos.

La inversión de la matriz de gram se puede hacer clásica o cuántica.

Este método es la versión cuántica del kernel clásico: B. Schölkopf, A. Smola, Learning with Kernels: Support Vector Machines, Regularization, Optimization, and Beyond (The MIT Press, Cambridge, 2018)

# Implementaciones físicas, Xanadu



quantum optical processors specialized for boson sampling



# Thank you!

[crbellor@unal.edu.co](mailto:crbellor@unal.edu.co)

# Notebook

<https://github.com/QUANTA-Research-Group/QML-Seminar>

kernelexample.ipynb

Quantum Science and Technology

Claudio Conti

# Quantum Machine Learning

Thinking and Exploration in Neural Network Models for Quantum Science and Quantum Computing

 Springer

Fecha	Charla
Mayo 10, 2025	Data-Driven Quantum Mechanics
Mayo 31, 2025	Kernel Method, Support Vector Machines (SVM) and Quantum Feature Map
	Practice with TensorFlow
	Keynote Luis Serrano